

Corpus: Software com IA Generativa

Catálogo de 3 papers seminais do arXiv usados como **corpus de retrieval** nos labs do M2 (LAB-002, LAB-003, LAB-004) e como referência teórica nos slides do instrutor.

Critério de Seleção

- **Open-access** em arXiv com URL estável de PDF
- **Foundational** — textos canônicos que o aluno encontra em qualquer leitura séria sobre LLMs
- **Tamanho moderado** (15-20 páginas cada) — suficiente para gerar ~150 chunks ao todo, manejo confortável em Chroma local
- **Diversidade de tópicos** que cobre LO M2-O1..O5 (mecanismo de geração → RAG → context decisions)
- **Licença** que permite redistribuição educacional sem fricção

Catálogo

1. Attention Is All You Need

Campo	Valor
Autores	Vaswani, Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser, Polosukhin
Ano	2017
arXiv ID	1706.03762
URL do PDF	https://arxiv.org/pdf/1706.03762v7.pdf
Páginas	~15
Tamanho aprox.	~2.2 MB
Licença	arXiv non-exclusive distribution license
SHA256	(populado por <code>download.py</code> na primeira execução)
Cobertura LO	M1-O1 (mecanismo de atenção/geração token-a-token); contexto teórico para todo M2

Por que está no corpus: quando aluno pergunta “o que é attention?” durante o LAB-002, o pipeline RAG deve retornar trechos deste paper. É o ponto canônico para validar `faithfulness` em LAB-003.

2. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

Campo	Valor
Autores	Lewis, Perez, Piktus, Petroni, Karpukhin, Goyal, Küttler, Lewis, Yih, Rocktäschel, Riedel, Kiela
Ano	2020
arXiv ID	2005.11401
URL do PDF	https://arxiv.org/pdf/2005.11401v4.pdf
Páginas	~19
Tamanho aprox.	~1.5 MB
Licença	arXiv non-exclusive distribution license
SHA256	(populado por <code>download.py</code> na primeira execução)
Cobertura LO	M2-O1 (etapas do pipeline RAG), M2-O2 (implementação)

Por que está no corpus: paper que estabelece a arquitetura RAG (retriever + generator). Queries como “qual a diferença entre fine-tuning e RAG?” devem retornar trechos daqui — é validação semântica direta no LAB-003.

3. Lost in the Middle: How Language Models Use Long Contexts

Campo	Valor
Autores	Liu, Lin, Hewitt, Paranjape, Bevilacqua, Petroni, Liang
Ano	2023
arXiv ID	2307.03172
URL do PDF	https://arxiv.org/pdf/2307.03172v3.pdf
Páginas	~19
Tamanho aprox.	~1.8 MB
Licença	arXiv non-exclusive distribution license
SHA256	(populado por <code>download.py</code> na primeira execução)
Cobertura LO	M2-O5 (justificar chunking/retrieval por domínio), M2-O4 (diagnosticar falhas), M3-O1 (custo/latência via context window)

Por que está no corpus: mostra empiricamente que LLMs degradam quando informação relevante está no meio do contexto. Justifica decisões de chunking e top-k no LAB-002 e diagnóstico de falha no LAB-004 (cenário B “retrieval mismatch” se relaciona diretamente com o “perdido no meio”).

Tamanho Total

Métrica	Valor
Papers	3
Páginas totais	~53
Tamanho total	~5.5 MB (< 10 MB; pode commitar direto OU usar <code>download.py</code>)
Chunks estimados	~150 (chunk_size=800, overlap=100)
Embeddings (gemini-embedding-001)	~150 chamadas; cabe em 1 sessão do free tier

Como Usar

Opção 1 — Commitar PDFs direto (recomendado para a turma de 2026-06-02):

```
python corpus/download.py
# Move data/corpus/*.pdf para o repositório
cp data/corpus/*.pdf ../delivery/datasets/corpus/
```

Opção 2 — Cada aluno baixa localmente (preserva repo leve):

```
cd <discipline-root>
python corpus/download.py # baixa para data/corpus/ e verifica SHA256
```

Licenciamento

Os 3 papers estão no arXiv sob a **arXiv non-exclusive distribution license** ([detalhes](#)), que permite redistribuição com atribuição de autoria. Uso educacional em sala de aula é cobertura confortável; **não redistribuir** os PDFs em produtos comerciais sem autorização adicional.

Alternativas Consideradas e Rejeitadas

Paper	Motivo da rejeição
Sentence-BERT (Reimers & Gurevych, 2019)	Mais técnico que pedagógico; chunking não traz tantos questionamentos espontâneos
ColBERTv2 (Santhanam et al, 2022)	Excelente para M2-O5 mas denso demais para 18h sem aprofundar
Self-RAG (Asai et al, 2023)	Tema avançado; melhor como referência opcional para alunos da trilha Advanced
Sparks of AGI (Bubeck et al, 2023)	154 páginas; quebra o LAB-002
Anthropic “Constitutional AI”	Off-topic para LLM-as-tool; foca em alignment

SHA256SUMS

Ver `SHA256SUMS` neste diretório (populado após primeira execução de `download.py`).