

Setup dos Notebooks — Guia rapido do aluno

Como criar o ambiente, iniciar o Jupyter e rodar os notebooks nas 3 aulas. Leia uma vez antes do Day-1. Use como referencia quando algo travar.

1. Pre-requisitos (verifique antes da aula)

Item	Como verificar	Como instalar se faltar
Python 3.10+	<code>python3 --version</code>	python.org/downloads
<code>uv</code>	<code>uv --version</code>	<code>curl -LsSf https://astral.sh/uv/install.sh sh</code>
Editor (VS Code recomendado)	—	code.visualstudio.com
Conta com API key (Gemini default)	—	aistudio.google.com/apikey

`uv` substitui `python -m venv` + `pip`. É ~10x mais rapido e cuida do lockfile.

2. Criar o ambiente (1 vez no Day-1, ~3 min)

Tudo acontece na **raiz da pasta descompactada** (`software-com-ia-generativa/`), onde ficam o `pyproject.toml` e o `uv.lock` que vieram no ZIP:

```
cd software-com-ia-generativa

# uv le pyproject.toml + uv.lock, cria .venv/ e instala TODAS as deps na versao
# exata validada (openai, chromadb, ragas, langchain-*, sentence-transformers, jupyter...).
uv sync
```

Depois desse comando voce tem: - `.venv/` na raiz da pasta (~3 GB com torch e transformers) - Kernel Jupyter `python3` ja registrado apontando pro `.venv` - As dependencias na versao exata do `uv.lock` que veio no ZIP

Validacao rapida:

```
uv run python -c "import openai, chromadb, ragas; print('OK')"
```

Deve imprimir `OK`. Se falhar, ver [S7 Troubleshooting](#).

3. Configurar a API key (1 vez)

Guia completo passo-a-passo: [API-KEYS.pdf](#). Cobre os 5 caminhos da disciplina (3 free + 2 pagos com US\$5 de credito):

Caminho	Provider	Quando usar
A (default)	Google Gemini	Voce tem conta Google — 30s pra gerar a chave
B	Groq	Sem conta Google ou quer latencia ~10x menor (sem embeddings)
C	Ollama local	100% offline, sem chave, sem rate limit
D	OpenAI	Medir custo USD real no LAB-005 (tem embeddings)
E	Anthropic	Medir custo USD real no LAB-005 (sem embeddings)

Gemini (A) e carregado automaticamente pelos notebooks (Colab Secrets → `.env` → prompt). Os Caminhos **B-E** sao alternativas e exigem editar a 1a celula do notebook (ver `API-KEYS.pdf` , secao “Como o notebook escolhe o provider”).

Resumo (Caminho A, local): crie um arquivo `.env` na raiz da disciplina (`software-com-ia-generativa/.env`) com **uma** das linhas abaixo:

```
# Caminho A (default da turma)
GEMINI_API_KEY=AIZA...sua-key-aqui

# OU Caminho B
GROQ_API_KEY=gsk...sua-key-aqui

# OU Caminho C (Ollama local)
OPENAI_API_KEY=ollama-local
OPENAI_BASE_URL=http://localhost:11434/v1
LLM_MODEL=qwen3:8b

# OU Caminho D (OpenAI)
OPENAI_API_KEY=sk-...sua-key-aqui

# OU Caminho E (Anthropic)
ANTHROPIC_API_KEY=sk-ant-...sua-key-aqui
```

Caminhos B e E nao tem embeddings — nos LAB-002/003/004 use `sentence-transformers` local (ja vem no `uv sync`) ou embeddings de Gemini/OpenAI. Detalhes no `API-KEYS.pdf` .

O `.env` esta no `.gitignore` global do repo. Nunca commite a chave. Leia `API-KEYS.pdf` para passo-a-passo, quotas, troubleshooting e checklist de seguranca.

4. Iniciar o Jupyter Lab (todo dia de aula)

Da raiz da disciplina:

```
uv run jupyter lab notebooks/
```

Isso abre o Jupyter no browser ja apontado pra pasta dos notebooks. Clique em qualquer `NN-*.ipynb` pra abrir.

`uv run <cmd>` executa qualquer comando dentro do `.env` **sem precisar de** `source .env/bin/activate` , Funciona pro `python` , `pytest` , `jupyter` , etc.

4.1 Rodar no Google Colab (fallback)

Se o setup local falhar, da pra rodar tudo no Colab:

- Suba o notebook (`NN-*.ipynb`) em colab.research.google.com.
- Chave:** painel de **Secrets** (icone de **chave**) → adicione `GEMINI_API_KEY` → ative **Notebook access**. A 1a célula le o Secret sozinha (no Colab não se usa `.env`).
- Dependências** (não há `uv sync` no Colab) — rode numa célula no topo:

```
!pip install -q openai chromadb pypdf langchain-text-splitters pydantic \
python-dotenv pandas matplotlib ragas datasets sentence-transformers langchain-google-genai
```

- Corpus** (LAB-002/003/004): suba a pasta `datasets/` e rode `!python datasets/download.py`, ou faça upload dos 3 PDFs para `data/corpus/`.

Ollama (Caminho C) não funciona no Colab free (sem servidor local). Use Gemini (default).

5. Verificar o kernel correto (1a vez que abrir o notebook)

No canto superior direito do notebook, deve aparecer `Python 3 (ipykernel)` apontando pro `.venv` da disciplina. Se aparecer outro kernel:

- Menu **Kernel** > **Change Kernel...**
- Escolha `Python 3 (ipykernel)`
- Rode a primeira célula — se imprimir `OK`, está no kernel certo

6. Fluxo dos 3 dias

Cada dia você vai rodar 2-3 notebooks na ordem:

Dia	Notebooks	Tempo lab	Foco
Day-1 (02/06)	<code>00</code> , <code>01</code>	14:00–16:45	Cliente LLM + Agent tool-use
Day-2 (03/06)	<code>02</code> , <code>03</code> , <code>04</code>	14:00–16:45	RAG + RAGAS + diagnostico
Day-3 (08/06)	<code>05</code> , <code>06</code>	10:00–16:45	Cache/routing + projeto

Rotina em cada lab:

- Abra o notebook (`NN-*.ipynb`)
- Leia a primeira célula (objetivos e checkpoint)
- Execute célula-por-célula com `Shift+Enter`
- Quando ver `# SEU CODIGO AQUI`, **complete o código antes de rodar a próxima**
- Use o PDF correspondente em `labs/lab-NNN.pdf` como manual de consulta

***Importante:** o notebook é a fonte da verdade. Se o PDF do lab divergir, siga o notebook.*

7. Troubleshooting

Sintoma	Diagnostico	Fix
<code>uv: command not found</code>	<code>uv</code> nao instalado	Rodar o <code>curl</code> do passo 1 e abrir novo terminal
<code>uv sync</code> trava em <code>torch</code>	rede lenta ou disco cheio	<code>df -h</code> (verificar disco), aguardar — <code>torch</code> pesa ~750 MB
<code>ModuleNotFoundError: openai</code> no notebook	kernel errado	\$5 — trocar para <code>Python 3 (ipykernel)</code>
<code>KeyError: 'GEMINI_API_KEY'</code>	<code>.env</code> ausente ou em pasta errada	\$3 — arquivo deve estar em <code>software-com-ia-generativa/.env</code>
<code>401 Unauthorized</code> (Gemini)	key invalida ou expirada	Gerar nova em aistudio.google.com/apikey
<code>429 Too Many Requests</code>	rate limit do free tier	Aguardar 60s; ou trocar pra OpenAI/Ollama
Notebook 02 nao acha PDFs	corpus nao foi baixado	<code>uv run python datasets/download.py</code>
Jupyter abre mas sem deps	rodou <code>jupyter</code> fora do venv	Sempre use <code>uv run jupyter lab</code> , nunca <code>jupyter</code> solto

Se nada disso resolveu, peca ajuda no plantao (instrutor + preceptor circulam nas tardes). Mande print do erro completo, nao so a ultima linha.

8. Comandos uteis

```
# Re-sincronizar apos pull do repo (caso deps mudem)
uv sync

# Validar um notebook sem abrir o Jupyter (igual ao instrutor faz no make check)
uv run pytest --nbval-lax notebooks/02-pipeline-rag.ipynb

# Ver versao de uma dep instalada
uv pip show chromadb

# Limpar outputs do notebook antes de comitar (se voce versionar o seu fork)
uv run nbstripout notebooks/*.ipynb
```