

Plano de aula — Desenvolvendo Software com IA Generativa

Disciplina: Mod4 / PPI

Duração: 18 horas em 3 sessões (3 × 6h)

Datas: 02/06/2026 (Dia 1), 03/06/2026 (Dia 2), 08/06/2026 (Dia 3)

Horário: 10:00–12:00 (manhã) e 13:00–17:00 (tarde) em todos os dias

Modalidade: remota via Microsoft Teams

Instrutor: Nicksson Freitas + preceptor

1. Contexto da disciplina

LLMs deixaram de ser apenas uma API de chat e passaram a ser componente arquitetural de aplicações Python. Hoje integra-se um modelo generativo a uma pipeline, conecta-se a ferramentas via *function-calling*, ancora-se a resposta em conhecimento próprio com **RAG** e mede-se qualidade de forma automatizada com **RAGAS** (*Retrieval-Augmented Generation Assessment*). Esta disciplina cobre esse ciclo completo, do primeiro prompt ao deploy de uma demo pública, usando uma stack profissional (Gemini/OpenAI, Chroma, RAGAS, Streamlit) e práticas consolidadas de produção como cache semântico, model routing *cheap-first* e observabilidade.

O público são devs com Python sólido e **sem experiência prévia** com integração de LLMs. Por isso a disciplina parte do zero nos tópicos de generativa, mas avança rapidamente para integrações reais. A entrega final é um projeto de portfólio público combinando **LLM, Tool-use, RAG, Cache e Deploy**, apto a ser referenciado em um README profissional.

2. Pré-requisitos

Para acompanhar as 18h sem fricção, você deve trazer:

- **Python 3.10+** sólido: funções, classes, type hints, virtualenv e leitura de stack trace.
- **Ferramentas básicas:** Git, terminal (bash ou zsh), Jupyter Lab e um editor com suporte a `.ipynb`.
- **HTTP e JSON na prática:** `requests` ou `httpx`, status codes e manipulação de payloads.
- **Laptop pessoal** com Python 3.10+ disponível e permissão para instalar dependências. A instalação das libs, a configuração da API key e o download do corpus são **pré-requisitos que você faz por conta própria antes dos labs** (idealmente antes do Dia 1), seguindo `notebooks/SETUP.pdf` e `notebooks/API-KEYS.pdf` — ver §9.

Não é exigida experiência prévia com LLMs, RAG, embeddings ou agentes, já que a disciplina parte do zero nesses tópicos.

3. Objetivos da disciplina

Ao final das 18h você terá completado o ciclo de integração de LLMs em Python e estará apto a:

1. **Aplicar prompt engineering** — projetar prompts que controlam o comportamento do modelo usando mensagens de sistema (*role/system*), exemplos dentro do próprio prompt (*few-shot*), instruções de raciocínio passo a passo (*Chain-of-Thought*, **CoT**) e saídas estruturadas em JSON validadas com **Pydantic** (biblioteca Python de validação de dados). Aplicado a tarefas de **NLU** — *Natural Language Understanding*, ou compreensão de linguagem natural: extração de intenção, classificação e parsing de texto livre.
2. **Implementar function-calling (também chamado de tool-use)** — fazer o LLM decidir, durante a geração, quando chamar uma função/API externa e como parsear o retorno. O fluxo roda em loop *tool* → *LLM* → *tool* até o modelo ter informação suficiente para responder. O resultado é um **agente single-turn** (uma rodada de raciocínio + ferramenta por interação) capaz de buscar dados em sistemas reais antes de gerar a resposta final.
3. **Implementar pipeline RAG ponta-a-ponta** — **RAG** significa *Retrieval-Augmented Generation*, ou geração aumentada por recuperação. É o padrão que permite ao modelo responder com base no **seu** corpus (docs, papers, código) em vez de só usar o

- que aprendeu no treino. O pipeline cobre: *chunking* do documento, geração de *embeddings* (vetores que representam o sentido do texto), armazenamento e busca vetorial com **Chroma** (vector store local), e geração da resposta com Gemini ou OpenAI ancorada nos trechos recuperados.
4. **Avaliar qualidade RAG com RAGAS** — RAGAS (*Retrieval-Augmented Generation Assessment*) é um framework que calcula automaticamente, com auxílio de LLMs, três métricas centrais: ***faithfulness*** (a resposta gerada é fiel ao contexto recuperado, sem inventar?), ***answer relevancy*** (a resposta efetivamente responde à pergunta?) e ***context precision*** (os trechos recuperados eram realmente relevantes?). Com essas métricas você diagnostica falhas — *chunking* ruim, *retrieval* desalinhado ou alucinação — e age sobre a parte certa do pipeline.
 5. **Reduzir custo de inferência em ≥50%** — duas técnicas complementares: **cache semântico** (reaproveita respostas já geradas para perguntas com sentido semelhante, comparando *embeddings* em vez de strings exatas) e **model routing cheap-first** (tenta primeiro o modelo barato; só escala para o modelo caro se a resposta vier com baixa confiança). Aprendido na prática medindo custo por chamada antes e depois.
 6. **Compor README profissional + demo deployada em URL pública** — README é o arquivo `README.md` do repositório, principal vitrine de um projeto open-source. O seu deve conter problema resolvido, arquitetura, métricas observadas, custo por requisição e GIF de demo. A demo é a aplicação rodando ao vivo em uma URL pública (Streamlit Cloud, HuggingFace Spaces ou Fly.io). Juntos formam o artefato apto a entrar no seu **portfólio público** — exibível a recrutadores, clientes e comunidade.

4. Como o curso funciona

O curso é estruturado em **3 dias sequenciais** com a mesma forma:

Período	Formato	Atividade
Manhã (10:00–13:00)	Aula expositiva + live-coding	Slides + notebooks executados ao vivo
Tarde (14:00–16:45)	Lab guiado individual	Você roda os notebooks na sua máquina; instrutor em plantão
Tarde (16:45–17:00)	Exit-Ticket	5 questões formativas

Cada dia foi desenhado para você sair da **manhã com conhecimento suficiente** para fazer o **lab da tarde** sozinho.

5. Dia 1 (02/06) — Fundamentos LLM + Tool-use

5.1 Cronograma

Horário	Atividade
10:00–11:00	Boas-vindas + apresentação do plano + verificação rápida de ambiente (setup feito previamente — ver §9)
11:00–11:30	Aula 1.1 — Modelo mental do LLM
11:30–13:30	Aula 1.2 — Prompt engineering (<i>almoço 12:00–13:00</i>)
13:30–14:30	Aula 1.3 — Tool-use / Function calling
14:30–14:45	Resumo do lab da tarde
14:45–16:30	LAB-001 — Agent CLI Single-Turn (notebook 01)
16:30–16:45	Discussão entre pares — tradeoffs pure-prompt vs tool-use
16:45–17:00	Form Day-1 — Exit-Ticket M1 (5 questões) + entrega do Agent CLI no mesmo formulário

5.2 Aula 1.1 — Modelo mental do LLM (11:00–11:30)

Tokens, parâmetros (`temperature`, `top_p`) e *context window*. Como o modelo “vê” o texto e como esses parâmetros mudam a saída.

5.3 Aula 1.2 — Prompt engineering (11:30–13:30)

Role/system + *few-shot* (parte 1, antes do almoço) seguidos de Chain-of-Thought (**CoT**) e *structured output* validado com Pydantic (parte 2, depois do almoço). Pausa de almoço entre 12:00–13:00.

5.4 Aula 1.3 — Tool-use / Function calling (13:30–14:30)

Loop *tool* → *LLM* → *tool* e como o modelo decide quando chamar uma função externa. Live-coding sobre o `notebook 01` que será concluído individualmente no LAB-001 da tarde.

6. Dia 2 (03/06) — RAG ponta-a-ponta + Evaluation

6.1 Cronograma

Horário	Atividade
10:00–10:10	Recapitulação do Dia 1 + Q&A
10:10–11:00	Aula 2.1 — Por que RAG, embeddings, chunking strategies
11:00–12:00	Aula 2.2 — Pipeline RAG ponta-a-ponta
12:00–13:00	Almoço
13:00–14:00	Aula 2.3 — Evaluation com RAGAS
14:00–14:15	Resumo dos 3 labs da tarde
14:15–16:15	LAB-002/003/004 — Pipeline RAG, suite RAGAS, diagnóstico de 3 falhas
16:15–16:45	Briefing completo do Projeto Portfólio (30 min) — apresentação do <code>projeto-portfolio.pdf</code>
16:45–17:00	Form Day-2 — Exit-Ticket M2 (5 questões) + entrega do Diagnóstico RAG + briefing da dupla Day-3

6.2 Aula 2.1 — Por que RAG, embeddings, chunking (10:10–11:00)

Motivação do RAG (responder a partir do seu corpus, não só do treino), *embeddings* como representação vetorial de sentido, estratégias de *chunking* (tamanho, *overlap*, fronteira semântica).

6.3 Aula 2.2 — Pipeline RAG ponta-a-ponta (11:00–12:00)

Live-coding sobre o `notebook 02`: *chunking* → *embeddings* → indexação em Chroma → busca → geração ancorada nos trechos recuperados.

6.4 Aula 2.3 — Evaluation com RAGAS (13:00–14:00)

Três métricas centrais — *faithfulness*, *answer relevancy*, *context precision* — e como cada uma aponta para uma falha distinta do pipeline (*chunking* ruim, *retrieval* desalinhado, alucinação). Q&A sobre diagnóstico acontece *dentro do LAB* (instrutor e preceptor circulam pelos breakouts).

7. Dia 3 (08/06) — Projeto Portfólio em Produção

O Dia 3 é **100% mão na massa**. O briefing completo do projeto acontece no fim do Dia 2 (slot 16:15–16:45), então o aluno chega aqui com modalidade, rubrica e template já alinhados. Total efetivo no Dia 3: **5h de construção + 45 min de gravação**.

7.1 Cronograma

Horário	Atividade
10:00–12:00	Aula 3.1 — Kickoff + implementação RAG e tools
12:00–13:00	Almoço
13:00–16:00	Aula 3.2 — Cache, routing, deploy e README
16:00–16:45	Gravação da demo + Form Day-3 (entrega do Projeto Portfólio, 1 envio por dupla)
16:45–17:00	Encerramento + highlight reel

7.2 Aula 3.1 — Kickoff + implementação RAG e tools (10:00–12:00)

Abertura informal (≤5 min: recap das deadlines e como pedir ajuda), depois clone do `template-portfolio`, `uv sync` e primeiros TODOs em `rag.py` e `tools.py`. Esta aula tem formato de **construção orientada** — não há exposição extensa, o instrutor circula e desbloqueia.

7.3 Aula 3.2 — Cache, routing, deploy e README (13:00–16:00)

TODOs restantes em `cache.py`, `routing.py` e `streamlit_app.py`, seguidos de deploy em URL pública e finalização do README. Os tópicos de **cache, routing, observabilidade, deploy e README** ficam no PDF de slides como **referência consultável durante o desenvolvimento** — apresentados no briefing do Dia 2; você abre o PDF localmente enquanto codifica.

8. Projeto Portfólio (em duplas)

O Projeto Portfólio é desenvolvido **em duplas (2 alunos)** durante o Dia 3. Com 62 alunos, isso resulta em **31 projetos** — escala compatível com o tempo disponível e suficiente para cada dupla ter acompanhamento do instrutor + preceptor.

Toda especificação detalhada (modalidades, rubrica, 5 ideias pré-validadas, estrutura do template, formato do vídeo demo, política de duplas e plágio) está consolidada no documento dedicado `projeto-portfolio.pdf`, distribuído no mesmo pacote desta disciplina e apresentado no briefing de 16:15–16:45 do Dia 2.

8.1 Resumo (visão executiva)

Item	Resumo
Formato	Duplas (2 alunos por projeto)
Quando	Dia 3 (08/06), 10:00–17:00 — 5 h efetivas de construção + 45 min de gravação
Modalidades	A (Template + corpus próprio) ou B (Projeto autoral) — escolha confirmada no kickoff do Dia 3
Rubrica	40% técnica + 30% README + 20% custo/latência + 10% demo
Entrega	3 URLs (demo pública + repo + vídeo ≤3 min) via Forms até 17:00 do Dia 3
Peso na nota	60% da disciplina

8.2 Onde encontrar a especificação completa

- `projeto-portfolio.pdf` — briefing integral: modalidades, rubrica detalhada com 3 bandas, 5 ideias pré-validadas (corpus + tool + scope), estrutura do template, regras de duplas, formato do vídeo demo, checklist final
- Slides do Dia 3** — referência consultável durante o desenvolvimento (cache, routing, observabilidade, deploy, README)

9. Setup do ambiente (pré-requisito — feito antes dos labs)

O setup **não é um bloco de aula**. Você o executa **uma vez, por conta própria, antes de rodar os labs** (idealmente antes do Dia 1). O passo a passo completo vive junto do material dos labs, nos guias `notebooks/SETUP.pdf` e `notebooks/API-KEYS.pdf` — esta

seção apenas resume como obter o material e validar que está tudo no lugar. Se algo travar no início de uma aula, o preceptor te desbloqueia no plantão.

9.1 Baixar o material

Os arquivos da disciplina serão compartilhados via **SharePoint da turma** no início do Dia 1. Baixe o ZIP `software-com-ia-generativa.zip` e descompacte numa pasta local.

Estrutura após descompactar:

```
software-com-ia-generativa/
├─ README.pdf                # visão geral
├─ plano-de-aula-alunos.pdf   # este documento
├─ slides/                   # 3 PDFs (1 por dia)
├─ notebooks/                # 7 notebooks (.ipynb) + SETUP.pdf + API-KEYS.pdf
├─ guia-dos-labs.pdf          # troubleshooting consolidado dos 7 labs
├─ datasets/                 # corpus de 3 papers arXiv + download.py + README.pdf
├─ projetos/                 # projeto portfólio
│  └─ projeto-portfolio.pdf   # briefing + rubrica
│  └─ projeto-portfolio-anexo-tecnico.pdf # anexo técnico (consulta Day-3)
└─ template-portfolio/        # scaffold (Modalidade A)
```

9.2 Instalar dependências e configurar a API key

O passo a passo completo está em `notebooks/SETUP.pdf` e `notebooks/API-KEYS.pdf`, que acompanham os notebooks. Em resumo:

```
cd software-com-ia-generativa
uv sync                                # cria .venv e instala todas as deps
echo 'GEMINI_API_KEY=AIZA...' > .env  # default da turma (ver API-KEYS.pdf)
```

`SETUP.pdf` cobre ambiente, Jupyter, kernel e troubleshooting; `API-KEYS.pdf` cobre os caminhos free disponíveis, quotas e checklist de segurança.

9.4 Baixar corpus

```
python datasets/download.py # baixa 3 papers arXiv (~5.5 MB) e valida SHA256
```

9.5 Abrir Jupyter (smoke test, antes do Dia 1)

```
uv run jupyter lab notebooks/
```

Abra `00-cliente-llm-robusto.ipynb` e rode a primeira célula (warm-up de ~30 segundos). Você deve ver `ping` impresso. Se algo falhar, veja o §7 (Troubleshooting) do `SETUP.pdf` ou peça ajuda no plantão da tarde.

10. Material

Todos os documentos textuais são entregues em **PDF** para distribuição uniforme via SharePoint/Teams. Notebooks e scaffolds permanecem em formato executável (`.ipynb` , código Python).

- **SharePoint da turma:** link disponível no canal do Teams.
- **Plano de aula (este documento):** `plano-de-aula-alunos.pdf`
- **Briefing do projeto:** `projeto-portfolio.pdf` — apresentado no Dia 2, contém modalidades, rubrica, 5 ideias pré-validadas e regras de duplas.
- **Slides:** `slides/slides-0{1,2,3}-*.pdf` — 1 deck em PDF por dia.
- **Notebooks da aula:** `notebooks/00..06-*.ipynb` — 7 notebooks Jupyter executáveis (formato `.ipynb` por necessidade técnica).
- **Guia dos labs:** `guia-dos-labs.pdf` — referência consolidada com troubleshooting dos 7 labs.

- **Forms de entrega diários (Day-1, Day-2, Day-3):** aplicados ao vivo no fim de cada dia, consolidam exit-ticket + assignment + (Day-2) briefing da dupla. Links compartilhados no chat no início da tarde.
- **Template do projeto:** `projetos/template-portfolio/` — scaffold Python para a Modalidade A.

11. Sobre os datasets

11.1 Corpus de 3 papers arXiv

Usado nos labs **LAB-002**, **LAB-003** e **LAB-004** (todos do Dia 2). Baixados automaticamente pelo `datasets/download.py`.

Paper	Autores	Ano	Páginas
Attention Is All You Need	Vaswani et al	2017	15
Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks	Lewis et al	2020	19
Lost in the Middle: How LMs Use Long Contexts	Liu et al	2023	19

Métrica	Valor
Total	~5.5 MB
Páginas	~53
Chunks após split (800/100)	~150
Licença	arXiv non-exclusive distribution

11.2 Corpus do projeto (Dia 3)

Você **escolhe seu próprio corpus** para o Projeto Portfólio. Critérios:

- Tem corpus textual disponível (docs internas, livros open-source, papers, regulamentação)
- ≥ 3 perguntas plausíveis que se beneficiam de LLM + RAG + tool-use
- Demonstrável em ≤ 2 min em vídeo

12. Plantão da tarde — como pedir ajuda

Situação	O que fazer
Dúvida rápida (import, path, comando)	Mande no chat público ; o preceptor responde
Dúvida conceitual	Levante a mão na sala principal e ative o microfone
Quer ajuda 1:1 ou revisão de código	Entre no breakout “Plantão” — o instrutor vai até você
Travou >10 min na mesma task	Pula para a próxima e volta depois (especialmente em LAB-004)
API key não funciona	Mande no chat antes de tentar de novo — pode ser rate limit do free tier

13. Avaliação

Todas as entregas acontecem **dentro do horário de aula** — não há atividade ou entrega fora das 18h da disciplina.

Há **1 Form por dia** (Day-1, Day-2, Day-3), cada um agregando todas as entregas avaliativas daquele dia.

Item	Peso	Form / Quando
Exit-Ticket M1	5%	Form Day-1 — 16:45–17:00 do Dia 1 (5 questões formativas)
Assignment Agent CLI	15%	Form Day-1 — URL do <code>01-agent-cli-tool-use.ipynb</code> até 17:00 do Dia 1
Exit-Ticket M2 + Q&A coletivo Dia 2	10%	Form Day-2 — 16:45–17:00 do Dia 2 (quiz + briefing da dupla; Q&A coletivo às 16:25)
Assignment Diagnóstico RAG	10%	Form Day-2 — URL do <code>04-diagnostico-falhas-rag.ipynb</code> até 17:00 do Dia 2
Projeto Portfólio Integrador (em duplas)	60%	Form Day-3 — 3 URLs (demo + repo + vídeo ≤3 min) até 17:00 do Dia 3 — nota única por dupla

13.1 Como entregar os assignments

Há **1 Forms por dia** (Day-1, Day-2, Day-3) com link compartilhado no chat às 13:00 do respectivo dia. Cada Forms reúne **todas** as entregas avaliativas daquele dia — exit-ticket + assignment (+ briefing da dupla no Day-2). A janela de envio fecha às **17:00**.

1. **Salve** seu notebook como `.ipynb` (ex: `01-agent-cli-seunome.ipynb`)
2. **Faça upload** no seu Google Drive
3. Clique direito no arquivo → **Compartilhar** → muda para “**Qualquer pessoa com o link**” (Leitor)
4. **Copie o link** compartilhado e abra-o numa janela anônima para confirmar acesso público
5. Abra o **Form do dia** (link no chat às 13:00) e responda na ordem: identificação → questões do exit-ticket → campo de URL do notebook → campos opcionais
6. Faça login com sua conta Google quando solicitado (email é capturado automaticamente)
7. **Envie** — pode reenviar quantas vezes quiser dentro da janela; vale o último envio

⚠ **Confirme** que o link compartilhado abre numa janela anônima antes de submeter.

13.2 Como entregar o Projeto Portfólio (Dia 3, em duplas)

O Projeto Portfólio é entregue **em duplas**. A nota é única para os dois membros. Entrega tem **3 partes**, todas submetidas via Forms durante o slot de gravação (16:00–16:45 do Dia 3):

1. **URL pública da demo** (Streamlit Cloud / HuggingFace Spaces / FastAPI Fly.io)
2. **URL do repositório** (GitHub público com README profissional + GIF de demo)
3. **URL do vídeo demo** (≤3 min, gravado em Loom / MS Stream / OBS / Teams) — **ambos os alunos aparecem e falam**; cada um apresenta a frente de trabalho que liderou

O vídeo é **componente avaliativo** — substitui a apresentação ao vivo individual, inviável com 31 duplas em 1 h. O instrutor projeta uma amostra de 3–4 demos ao vivo no encerramento (16:45–17:00) como fechamento da disciplina.

Especificação completa do projeto (modalidades, 5 ideias pré-validadas, rubrica detalhada, regras de duplas, divisão de trabalho sugerida, checklist final): ver `projeto-portfolio.pdf`.

13.3 Rubrica do Projeto Portfólio (3-bandas, 100 pts ponderados)

Critério	Peso	Básico (60–74)	Sólido (75–89)	Excelente (90–100)
Técnica	40%	LLM+RAG+tool-use funcionam isoladamente	+ integração ponta-a-ponta com erros tratados	+ arquitetura justificada + código testado + eval automatizada
README	30%	problem statement + setup	+ diagrama + métricas observadas	+ decisões de design + GIF + custo/req
Custo/Latência	20%	mede custo por chamada	+ cache com hit-rate medido	+ routing cheap-first com redução ≥50% + P95 reportado
Demo	10%	URL acessível	+ 1 fluxo demonstrável sem crash	+ UX cuidada (streaming, loading states) + TTL declarado

Diferenciação por trilha adaptativa (não muda rubrica, muda target):

- Trilha **Basic** — target “básico” em todos os 4 critérios
- Trilha **Intermediate** — target “sólido” em ≥ 3 critérios
- Trilha **Advanced** — target “excelente” em ≥ 2 critérios

13.4 Faixas de nota

Score final	Conceito	Significado
85–100	A	Excelente — domínio completo, projeto apto a portfólio público
70–84	B	Bom — projeto sólido com 1 critério em “básico”
55–69	C	Básico — projeto funcional mas com gaps notáveis
0–54	D	Insuficiente — revisar notebooks 01-06 e refazer projeto

A nota final = **5% + 15% + 10% + 10% + 60% = 100%** dos 5 itens listados acima.

13.5 Política de prazo e plágio

- **Prazo:** todas as entregas são feitas via Forms **dentro do horário de aula** do dia da respectiva avaliação (até as 17:00). O Forms encerra junto com a aula; não há janela de entrega fora do horário.
- **Não entregou no horário:** o item correspondente fica zerado. Use o slot de plantão da tarde para resolver bloqueios e entregar antes do encerramento.
- **Plágio:** notebooks idênticos (sem variação relevante) recebem **zero para ambos**. Você pode discutir ideias com colegas no chat, mas o código deve ser seu.
- **Uso de IA na entrega: permitido e esperado** (é uma disciplina sobre LLMs). Mas: você deve **entender** o código que entrega — pode haver Q&A oral no dia da apresentação para validar.
- **Revisão de nota:** pode ser solicitada em até 3 dias após a divulgação, com justificativa técnica.

14. Leituras opcionais pós-curso

Esta seção é **referência para depois da disciplina** — não há leitura obrigatória fora do horário de aula. Use como roteiro de aprofundamento depois que o curso terminar.

14.1 Papers fundamentais (estão no corpus do Dia 2)

- **Vaswani et al (2017)** — *Attention Is All You Need* (NeurIPS) — origem dos Transformers
- **Lewis et al (2020)** — *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* (NeurIPS) — paper canônico do RAG

- **Liu et al (2023)** — *Lost in the Middle: How LMs Use Long Contexts* — implicações para chunking e top-k

14.2 Outros papers relevantes

- **Wei et al (2022)** — *Chain-of-Thought Prompting Elicits Reasoning* (NeurIPS) — base do CoT
- **Es et al (2024)** — *RAGAS: Automated Evaluation of Retrieval-Augmented Generation* (EACL) — framework usado no LAB-003
- **Asai et al (2023)** — *Self-RAG* — versão avançada do RAG com auto-reflexão

14.3 Ferramentas e SDKs

- [OpenAI Python SDK](#) — usado em todos os labs
- [Anthropic Python SDK](#) — alternativa
- [Google GenAI SDK](#) — provider default da turma
- [Chroma](#) — vector store local
- [RAGAS](#) — eval framework para RAG
- [Langfuse](#) — observabilidade LLM (opcional, Dia 3)
- [Ollama](#) — LLMs locais (Tier 3, sem cartão)

14.4 Recursos extras

- **Anthropic** — **Building effective agents** (2024) — guia oficial sobre quando usar tool-use vs orchestrators
- **OpenAI Cookbook** — receitas de prompt engineering atualizadas
- **HuggingFace LLM Course** (gratuito) — fundamentos sólidos se quiser ir mais fundo no treino

15. Em caso de problemas técnicos no dia

1. **Áudio/vídeo não funciona:** use o **chat** do Teams.
2. **Setup local falhou (você o fez antes da aula):** peça ajuda no chat — o preceptor te acompanha até o smoke test passar. Se persistir, alternamos para Google Colab ou breakout 1:1.
3. **Conexão caiu:** reconecte; a gravação cobre o que você perdeu.
4. **Forms de entrega não abre:** avise no chat — temos link backup.
5. **API key vazou em commit: avise o instrutor imediatamente** — vai precisar revogar a key no console do provider. Pre-commit hook deveria bloquear, mas se passou, atue rápido.
6. **Rate limit no Gemini free tier (Dia 2):** distribua as chamadas ao longo de minutos — 15 RPM significa 1 a cada 4s. Se precisar urgente, peça permissão para usar OpenAI free credit (\$5).

16. Resumo executivo (1 frase)

Você vai sair desta disciplina com **um produto LLM-powered deployado em URL pública** integrando LLM + RAG + Tool-use + Cache + Routing, apto a entrar no seu portfólio profissional.